Universidad De Guayaquil

Facultad De Ciencias Matemáticas Y Físicas

Ciencias De Datos E Inteligencias Artificial

Parcial 2 – Unidad 2 – Proyecto final

Sistema de Predicción de Deserción Estudiantil

Integrante:

Paul David Delgado Vergara

Curso:

CDDEIA-ELNO-5-2

Materia:

ALMACENES DE DATOS Y MINERÍA DE DATOS

Docente:

Ing. Oscar Leon

Periodo Académico:

2026 – 2027 CII

INFORME TÉNICO. –

Sistema de predicción de Deserción Estudiantil Basado en CRISP-DM

1. Comprensión del negocio. –

El problema abordado en este proyecto se centra en la necesidad de identificar estudiantes que presentan un alto riesgo de deserción académica. La deserción no suele depender de un único factor, sino de una combinación de variables relacionadas con el rendimiento académico, la asistencia y el historial de repitencias.

El objetivo principal de este proyecto es desarrollar un modelo predictivo capaz de clasificar a los estudiantes en función de su riesgo de deserción, permitiendo apoyar la toma de decisiones académicas. El sistema busca priorizar la detección temprana de estudiantes en riesgo, incluso si ello implica generar algunas falsas alertas, ya que resulta más crítico no detectar a un desertor potencial que advertir un riesgo inexistente.

El resultado esperado es una herramienta funcional que pueda ser utilizada como sistema de apoyo para docentes, coordinadores o autoridades académicas.

2. Comprensión de los datos (Data Understanding). –

El conjunto de datos que utilicé en el proyecto fue proporcionado en formato Excel y contiene información académica histórica de estudiantes de la carrera de ciencias de datos e inteligencia artificial. Cada registro corresponde a una materia cursada por un estudiante e incluye variables como el promedio académico, el porcentaje de asistencia, el estado de la materia y el número de veces que una asignatura ha sido cursada.

Durante la exploración inicial de los datos se identificaron las siguientes características relevantes:

El promedio académico se encontraba almacenado como texto, utilizando coma como separador decimal.

Un mismo estudiante podía tener múltiples registros asociados a diferentes materias.

La variable "estado" permitía identificar materias reprobadas, información clave para el análisis de riesgo académico.

A partir de esta comprensión inicial, se definió la necesidad de transformar y agregar la información a nivel de estudiante para poder realizar un análisis predictivo adecuado.

3. Preparación de los datos. –

En esta fase se realizaron diversas transformaciones con el objetivo de obtener un conjunto de datos limpio y adecuado para el modelado. En primer lugar, se convirtió la variable PROMEDIO a formato numérico flotante, reemplazando el separador decimal para garantizar su correcto procesamiento.

Posteriormente, se creó una variable auxiliar denominada reprobada, que permite identificar si una materia fue reprobada o no. Esta variable facilitó el cálculo del número total de materias reprobadas por cada estudiante.

A continuación, se realizó una agregación de los datos por estudiante, obteniendo variables representativas de su desempeño académico, tales como:

- Promedio general de calificaciones.
- Asistencia promedio.
- Número total de materias reprobadas.
- Máximo número de veces que un estudiante repitió una asignatura.
- Total de materias cursadas.

Esta variable permitió capturar de forma más precisa el desempeño académico global de cada estudiante.

4. Definición de la variable objetivo (Deserción). –

Dado que no se contaba con una variable explícita de deserción en el conjunto de datos original, se construyó una variable proxy basada en criterios académicos. Un estudiante fue considerado como desertor potencial cuando cumplía al menos una de las siguientes condiciones:

- Tasa de reprobación mayor o igual al 25 %.
- Asistencia promedio inferior al 70 %.
- Promedio general inferior a 6.5.
- Haber repetido una asignatura dos o más veces.
- Tener tres o más materias reprobadas.

La combinación de estos criterios permitió definir la variable binaria deserción, donde el valor 1 representa a un estudiante con riesgo de abandono y el valor 0 a un estudiante sin riesgo. Posteriormente, se verificó la distribución de clases para asegurar que la proporción de desertores se encontrara en un rango razonable, evitando sesgos extremos en el entrenamiento del modelo.

5. Modelado. –

Para la etapa de modelado se seleccionó el algoritmo Random Forest Classifier, debido a su capacidad para manejar relaciones no lineales, su robustez frente al ruido y su buen desempeño en problemas de clasificación con múltiples variables explicativas.

Las variables independientes utilizadas en el modelo fueron:

- Promedio general.
- Asistencia promedio.
- Número de materias reprobadas.
- Máximo número de repeticiones de una asignatura.

El modelo fue entrenado exitosamente utilizando 100 árboles de decisión y parámetros ajustados para evitar el sobreajuste.

6. Evaluación. –

El desempeño del modelo fue evaluado utilizando métricas estándar de clasificación. Se calculó el accuracy, así como el reporte de clasificación que incluye precisión, recall y F1-score para cada clase. Asimismo, se generó la matriz de confusión, la cual permitió analizar los distintos tipos de predicción.

Los resultados obtenidos muestran que el modelo logra identificar de manera adecuada a los estudiantes con riesgo de deserción. Se pone especial énfasis en el recall de la clase "desertor", ya que el objetivo principal del sistema es minimizar los casos de estudiantes en riesgo que no sean detectados.

También se analizó la importancia de las variables, observándose que el promedio académico y la asistencia son los factores más influyentes en la predicción, lo cual concuerda con la literatura educativa y el criterio académico.

7. Despliegue. –

Como etapa final del proceso CRISP-DM, el modelo entrenado fue integrado en una aplicación web desarrollada con Streamlit. La aplicación permite al usuario ingresar información académica básica de un estudiante y obtener de forma inmediata una predicción del riesgo de deserción, junto con la probabilidad asociada.

La interfaz fue diseñada de manera intuitiva, incorporando mensajes claros, indicadores visuales y una explicación general del propósito del sistema. De esta forma, la herramienta se presenta como un sistema de apoyo a la toma de decisiones académicas, facilitando su uso por parte de personal no técnico.

8. Conclusiones. –

El presente proyecto demuestra que es posible aplicar técnicas de minería de datos y aprendizaje automático para abordar el problema de la deserción estudiantil de manera efectiva. La utilización de la metodología CRISP-DM permitió estructurar el proceso de forma ordenada y justificable, desde la comprensión del problema hasta el despliegue de una solución funcional.

El modelo Random Forest mostró un desempeño adecuado y permitió identificar las variables académicas más relevantes asociadas al riesgo de abandono. Finalmente, la implementación de la

aplicación Streamlit evidencia el potencial del proyecto para ser utilizado en un entorno real como herramienta de apoyo institucional.